

15. Clustering y segmentación exploratoria con k-means

15.1. Objetivo de la sección

En la sección anterior trabajamos con regresión lineal. Allí definimos una variable respuesta y utilizamos otras variables para intentar describirla o predecirla.

En esta sección abordaremos un problema diferente.

Supongamos que tenemos muchas observaciones y queremos responder:

¿Existen grupos de observaciones con características similares?

Pero ahora no tenemos una columna que indique previamente a qué grupo pertenece cada observación.

Este tipo de problema pertenece al aprendizaje no supervisado.

Trabajaremos con:

- selección de variables para clustering;
- tratamiento de valores faltantes;
- concepto de distancia;
- importancia de la escala de las variables;
- estandarización;
- algoritmo **k-means**;
- selección exploratoria del número de clusters;
- asignación de grupos a las observaciones;
- caracterización de los clusters;
- visualización e interpretación;
- limitaciones del procedimiento.

Idea clave

En clustering no indicamos previamente cuál es la respuesta correcta. El algoritmo intenta encontrar estructura a partir de las características de las observaciones.

15.2. Una pregunta exploratoria

Utilizaremos nuevamente la base meteorológica.

Podemos plantear una pregunta como:

¿Es posible identificar grupos de días con condiciones meteorológicas semejantes?

Por ejemplo, podríamos caracterizar cada día utilizando:

- temperatura media;
- humedad relativa media;
- radiación solar;
- precipitación;
- amplitud térmica.

No vamos a indicar previamente si un día es:

- cálido;
- frío;
- seco;
- húmedo;
- lluvioso.

Queremos observar si los datos producen agrupamientos que luego podamos interpretar.

Idea clave

Los clusters no tienen significado automático. Primero se calculan los grupos y después debemos estudiar qué características tienen.

15.3. Preparar los datos

Comenzamos cargando los paquetes y la base procesada.

Preparar el entorno

```
1 library(tidyverse)
2
3 datos <- read_csv(
4   "data/processed/datos_meteorologicos_tidyverse.csv"
5 )
6
7 glimpse(datos)
```

Construimos una tabla con las variables que utilizaremos:

Seleccionar variables para clustering

```
1  datos_cluster <- datos %>%
2    select(
3      Fecha,
4      estacion,
5      temp_media,
6      hr_media,
7      rad_solar,
8      precipitacion,
9      amplitud_termica
10 )
11
12 glimpse(datos_cluster)
```

Buena práctica

Las variables utilizadas para construir clusters deben seleccionarse porque tienen sentido para la pregunta planteada, no solamente porque están disponibles.

15.4. Comenzar con una estación

Como primera experiencia, puede ser conveniente trabajar con una sola estación.

Esto evita que diferencias estructurales entre estaciones dominen inicialmente el agrupamiento.

Seleccionar una estación

```
1  estacion_elegida <- "La Estanzuela"
2
3  datos_cluster <- datos_cluster %>%
4    filter(
5      estacion == estacion_elegida
6    )
7
8  glimpse(datos_cluster)
```

Idea clave

Antes de agrupar observaciones procedentes de fuentes diferentes, conviene preguntarse si esas fuentes son realmente comparables.

15.5. Revisar valores faltantes

El algoritmo k-means no puede trabajar directamente con valores faltantes.

Primero revisamos su presencia:

Revisar faltantes

```
1 datos_cluster %>%
2   summarise(
3     across(
4       everything(),
5       ~ sum(is.na(.x))
6     )
7   )
```

Para este ejemplo utilizaremos observaciones completas en las variables elegidas:

Preparar registros completos

```
1 datos_cluster_completos <- datos_cluster %>%
2   drop_na(
3     temp_media,
4     hr_media,
5     rad_solar,
6     precipitacion,
7     amplitud_termica
8   )
9
10 cat(
11   "Registros originales:",
12   nrow(datos_cluster),
13   "\n"
14 )
15
16 cat(
17   "Registros utilizados:",
18   nrow(datos_cluster_completos),
19   "\n"
20 )
```

Buena práctica

Eliminar observaciones faltantes puede cambiar la composición de los datos. Siempre debemos registrar cuántas observaciones quedan fuera del análisis.

15.6. Separar identificadores y variables de clustering

La fecha y el nombre de la estación son importantes para interpretar los resultados, pero no necesariamente deben utilizarse para calcular las distancias.

Construimos entonces una tabla solamente con las variables numéricas elegidas:

Matriz de variables

```
1 variables_cluster <- datos_cluster_completos %>%
2   select(
3     temp_media,
4     hr_media,
5     rad_solar,
6     precipitacion,
7     amplitud_termica
8   )
9
10 glimpse(variables_cluster)
```

Idea clave

No todas las columnas de una base deben entrar en el clustering. Identificadores, códigos y fechas pueden ser fundamentales para interpretar las observaciones, pero no necesariamente para calcular semejanzas.

15.7. La idea de distancia

El clustering necesita alguna forma de cuantificar qué tan similares o diferentes son dos observaciones.

Una distancia frecuente es la distancia euclídea.

Para dos observaciones con variables $x_1, \dots, x_p$:

$$d(x, y) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

Si tenemos dos variables, podemos pensarla como la distancia ordinaria entre dos puntos del plano.

Idea clave

El resultado de un método basado en distancias depende directamente de las variables utilizadas y de sus escalas.

15.8. El problema de las escalas

Supongamos que utilizamos:

- temperatura, aproximadamente entre 10 y 35;

- humedad, aproximadamente entre 20 y 100;
- radiación solar, con valores de varios cientos;
- precipitación, frecuentemente próxima a cero pero ocasionalmente mucho mayor.

Si calculamos distancias directamente, las variables con mayor escala numérica pueden tener una influencia mucho mayor.

Idea clave

Una variable no debería ser más importante solamente porque está expresada con números mayores.

15.9. Estandarizar las variables

Una estrategia frecuente consiste en transformar cada variable mediante:

$$z = \frac{x - \bar{x}}{s},$$

donde:

- $\bar{x}$ es la media de la variable;
- s es su desviación estándar.

Después de esta transformación, cada variable tendrá aproximadamente:

$$\text{media} = 0$$

y

$$\text{desviación estándar} = 1.$$

En R podemos utilizar:

Estandarizar variables

```
1 variables_escaladas <- scale(
2   variables_cluster
3 )
```

Podemos revisar:

Revisar variables estandarizadas

```
1 head(variables_escaladas)
```

Y comprobar sus medias:

Medias después de estandarizar

```
1 colMeans(  
2     variables_escaladas  
3 )
```

También podemos revisar las desviaciones estándar:

Desviaciones estándar

```
1 apply(  
2     variables_escaladas,  
3     2,  
4     sd  
5 )
```

Buena práctica

En métodos basados en distancias, siempre debemos revisar si las variables necesitan ser escaladas.

15.10. El algoritmo k-means

El algoritmo **k-means** busca dividir las observaciones en k grupos.

De forma simplificada, el procedimiento es:

1. elegir k centros iniciales;
2. asignar cada observación al centro más cercano;
3. recalcular el centro de cada grupo;
4. volver a asignar observaciones;
5. repetir hasta que las asignaciones se estabilicen.

Cada centro se denomina **centroide**.

Idea clave

El valor de k debe definirse antes de ejecutar `k-means`.

15.11. Primer modelo con $k = 3$

Comencemos suponiendo que queremos tres grupos.

Antes de ejecutar el algoritmo fijamos una semilla:

Fijar semilla

```
1 set.seed(123)
```

Luego:

Ajustar k-means

```
1 modelo_k3 <- kmeans(  
2   variables_escaladas,  
3   centers = 3,  
4   nstart = 25  
5 )  
6  
7 print(modelo_k3)
```

Cómo leer este código

El argumento:

Terminal

```
centers = 3
```

indica que queremos construir tres clusters.

El argumento:

Terminal

```
nstart = 25
```

hace que el algoritmo pruebe diferentes configuraciones iniciales y conserve una solución apropiada entre ellas.

Buena práctica

Como k-means depende de centros iniciales, conviene utilizar múltiples inicializaciones y fijar una semilla para obtener resultados reproducibles.

15.12. Agregar el cluster a la base

El objeto generado por `kmeans` contiene la asignación de cada observación:

Ver primeras asignaciones

```
1 head(  
2     modelo_k3$cluster  
3 )
```

Podemos agregar esa información a nuestra tabla original:

Agregar clusters

```
1 resultado_cluster <- datos_cluster_completos %>%  
2   mutate(  
3     cluster =  
4       factor(  
5         modelo_k3$cluster  
6       )  
7   )  
8  
9 resultado_cluster %>%  
10  select(  
11    Fecha,  
12    temp_media,  
13    hr_media,  
14    rad_solar,  
15    precipitacion,  
16    amplitud_termica,  
17    cluster  
18  ) %>%  
19  head()
```

Idea clave

Los números 1, 2 y 3 no tienen un significado natural. Son solamente identificadores de los grupos encontrados.

15.13. ¿Cuántas observaciones tiene cada cluster?

Podemos comenzar contando:

Tamaño de los clusters

```
1 resultado_cluster %>%  
2   count(  
3     cluster  
4   )
```

Esto permite detectar, por ejemplo, si un cluster contiene solamente unas pocas observaciones.

Buena práctica

El tamaño de los clusters forma parte de la interpretación. Un grupo extremadamente pequeño puede representar un comportamiento particular, observaciones extremas o una solución poco estable.

15.14. Caracterizar los clusters

Ahora podemos estudiar las características promedio de cada grupo.

Resumen por cluster

```
1 perfil_clusters <- resultado_cluster %>%  
2   group_by(  
3     cluster  
4   ) %>%  
5  
6   summarise(  
7     registros = n(),  
8  
9     temp_media =  
10      mean(  
11        temp_media,  
12        na.rm = TRUE  
13      ),  
14  
15     hr_media =  
16      mean(  
17        hr_media,  
18        na.rm = TRUE  
19      ),  
20  
21     rad_solar =
```

```

22         mean(
23             rad_solar,
24             na.rm = TRUE
25         ),
26
27         precipitacion =
28             mean(
29                 precipitacion,
30                 na.rm = TRUE
31             ),
32
33         amplitud_termica =
34             mean(
35                 amplitud_termica,
36                 na.rm = TRUE
37             ),
38
39         .groups = "drop"
40     )
41
42 print(perfil_clusters)

```

Idea clave

La interpretación comienza después del clustering. Debemos observar qué distingue a cada grupo.

A partir de este resumen podríamos encontrar, por ejemplo, un grupo caracterizado por:

- mayor temperatura;
- menor humedad;
- mayor radiación;

y otro con:

- mayor humedad;
- menor radiación;
- mayor precipitación.

Pero esas interpretaciones deben surgir de los resultados y no definirse de antemano.

15.15. Examinar los centroides estandarizados

El objeto del modelo contiene los centroides:

Centroides

```
1 modelo_k3$centers
```

Como utilizamos variables estandarizadas:

- valores positivos indican valores por encima de la media;
- valores negativos indican valores por debajo de la media.

Por ejemplo, un centroide podría mostrar:

Terminal

```
temp_media      0.8
hr_media        -0.7
rad_solar       0.9
precipitacion   -0.4
amplitud_termica 0.5
```

Una posible lectura sería:

Este cluster presenta, en promedio, temperaturas y radiación superiores a la media y humedad inferior a la media.

Idea clave

Trabajar con centroides estandarizados facilita comparar variables que originalmente utilizaban escalas diferentes.

15.16. Visualizar los clusters

Aunque el algoritmo utilice cinco variables, podemos observar proyecciones utilizando dos variables.

Por ejemplo:

Temperatura y humedad por cluster

```
1 ggplot(  
2   resultado_cluster,  
3   aes(  
4     x = temp_media,  
5     y = hr_media,  
6     color = cluster  
7   )  
8 ) +
```

```

9     geom_point() +
10     labs(
11         title = "Clusters de condiciones meteorologicas",
12         subtitle = "Proyeccion sobre temperatura y humedad",
13         x = "Temperatura media",
14         y = "Humedad relativa media",
15         color = "Cluster"
16     ) +
17     theme_minimal()

```

Podemos construir otra visualización:

Radiación y precipitación por cluster

```

1  ggplot(
2      resultado_cluster,
3      aes(
4          x = rad_solar,
5          y = precipitacion,
6          color = cluster
7      )
8  ) +
9      geom_point() +
10     labs(
11         title = "Clusters de condiciones meteorologicas",
12         subtitle = "Proyeccion sobre radiacion y precipitacion",
13         x = "Radiacion solar",
14         y = "Precipitacion",
15         color = "Cluster"
16     ) +
17     theme_minimal()

```

Error frecuente

Si dos clusters aparecen mezclados en un gráfico de dos variables, eso no significa necesariamente que el algoritmo no haya encontrado diferencias. El clustering fue realizado utilizando todas las variables seleccionadas.

15.17. Observar los clusters en el tiempo

Como conservamos la fecha original, podemos estudiar cuándo aparecen los diferentes grupos.

Cluster a lo largo del tiempo

```
1 ggplot(  
2   resultado_cluster,  
3   aes(  
4     x = Fecha,  
5     y = temp_media,  
6     color = cluster  
7   )  
8 ) +  
9   geom_point() +  
10  labs(  
11    title = "Clusters a lo largo del tiempo",  
12    x = "Fecha",  
13    y = "Temperatura media",  
14    color = "Cluster"  
15  ) +  
16  theme_minimal()
```

Esto puede sugerir preguntas como:

- ¿algunos clusters aparecen principalmente en determinadas estaciones del año?;
- ¿existen períodos dominados por un tipo de comportamiento?;
- ¿los clusters representan principalmente diferencias estacionales?;

Idea clave

Una vez obtenidos los clusters, podemos relacionarlos nuevamente con variables que no fueron utilizadas para construirlos.

15.18. ¿Cómo elegir el número de clusters?

Hasta ahora utilizamos $k = 3$ arbitrariamente.

Podemos comparar diferentes valores de k .

Una medida disponible en el resultado de `kmeans` es:

Terminal

```
tot.withinss
```

que representa la variabilidad interna total de los clusters.

Cuanto menor sea este valor, más próximas están las observaciones a sus respectivos centroides.

Comparar diferentes valores de k

```
1 resultados_k <- tibble(  
2   k = 1:10,  
3   withinss = NA_real_  
4 )  
5  
6 for (i in 1:10) {  
7  
8   set.seed(123)  
9  
10  modelo <- kmeans(  
11    variables_escaladas,  
12    centers = i,  
13    nstart = 25  
14  )  
15  
16  resultados_k$withinss[i] <-  
17    modelo$tot.withinss  
18 }  
19  
20 print(resultados_k)
```

Podemos graficar:

Método del codo

```
1 ggplot(  
2   resultados_k,  
3   aes(  
4     x = k,  
5     y = withinss  
6   )  
7 ) +  
8   geom_line() +  
9   geom_point() +  
10  scale_x_continuous(  
11    breaks = 1:10  
12  ) +  
13  labs(  
14    title = "Variabilidad interna segun cantidad de clusters",  
15    x = "Cantidad de clusters",  
16    y = "Variabilidad interna total"  
17  ) +  
18  theme_minimal()
```

Cómo leer este código

Al aumentar k , la variabilidad interna siempre disminuye.

Por eso no buscamos simplemente el menor valor.

Buscamos un punto a partir del cual agregar nuevos clusters produce mejoras cada vez menores.

Idea clave

El método del codo es una herramienta exploratoria. No produce necesariamente una única respuesta correcta para k .

15.19. Otra medida: silhouette

También podemos estudiar qué tan bien queda asignada cada observación a su cluster.

Una herramienta frecuente es la medida de *silhouette*.

Para utilizarla cargamos:

Cargar paquete cluster

```
1 library(cluster)
```

Para nuestro modelo:

Calcular silhouette

```
1 distancias <- dist(  
2     variables_escaladas  
3 )  
4  
5 silhouette_k3 <- silhouette(  
6     modelo_k3$cluster,  
7     distancias  
8 )  
9  
10 summary(  
11     silhouette_k3  
12 )
```

Podemos obtener el promedio:

Silhouette promedio

```
1 media_silhouette <- mean(  
2     silhouette_k3[, "sil_width"]  
3 )  
4  
5 print(  
6     media_silhouette  
7 )
```

De forma general:

- valores mayores indican una separación más clara;
- valores próximos a cero indican observaciones cercanas a fronteras entre grupos;
- valores negativos pueden indicar observaciones posiblemente mejor asociadas a otro cluster.

Buena práctica

La selección de k puede combinar diferentes evidencias: métricas, visualizaciones, estabilidad e interpretación del problema.

15.20. Comparar silhouette para varios valores de k

Podemos construir una función:

Función para silhouette promedio

```
1 calcular_silhouette <- function(  
2     k,  
3     datos_escalados  
4 ) {  
5  
6     set.seed(123)  
7  
8     modelo <- kmeans(  
9         datos_escalados,  
10        centers = k,  
11        nstart = 25  
12    )  
13  
14    sil <- silhouette(  
15        modelo$cluster,  
16        dist(datos_escalados)  
17    )
```

```

18
19     return(
20         mean(
21             sil[, "sil_width"]
22         )
23     )
24 }

```

Luego:

Evaluar distintos valores de k

```

1  comparacion_k <- tibble(
2    k = 2:8
3  ) %>%
4
5    mutate(
6      silhouette =
7        map_dbl(
8          k,
9          ~ calcular_silhouette(
10             .x,
11             variables_escaladas
12           )
13        )
14    )
15
16 print(comparacion_k)

```

Y podemos visualizar:

Silhouette según k

```

1  ggplot(
2    comparacion_k,
3    aes(
4      x = k,
5      y = silhouette
6    )
7  ) +
8    geom_line() +
9    geom_point() +
10   scale_x_continuous(
11     breaks = 2:8
12   ) +

```

```

13     labs(
14         title = "Silhouette promedio segun cantidad de clusters",
15         x = "Cantidad de clusters",
16         y = "Silhouette promedio"
17     ) +
18     theme_minimal()

```

15.21. Valores extremos y clustering

Los valores extremos pueden afectar significativamente los centroides de **k-means**.

Por ejemplo, unos pocos días con precipitaciones excepcionalmente elevadas podrían modificar la estructura de los clusters.

Podemos revisar:

Examinar valores extremos

```

1 resultado_cluster %>%
2   arrange(
3     desc(precipitacion)
4   ) %>%
5
6   select(
7     Fecha,
8     precipitacion,
9     temp_media,
10    hr_media,
11    cluster
12  ) %>%
13
14  slice_head(
15    n = 10
16  )

```

Idea clave

Detectar una observación extrema no significa que debamos eliminarla. En meteorología, producción, economía y muchas otras áreas, los eventos extremos pueden ser precisamente las observaciones más interesantes.

15.22. Variables con distribuciones muy asimétricas

La precipitación suele presentar una característica particular:

- muchos días con valor cero;

- algunos días con valores pequeños;
- pocos días con valores muy elevados.

Podemos observar su distribución:

Distribución de precipitación

```

1 ggplot(
2   datos_cluster_completos,
3   aes(
4     x = precipitacion
5   )
6 ) +
7   geom_histogram(
8     bins = 30
9   ) +
10  labs(
11    title = "Distribucion de precipitacion",
12    x = "Precipitacion",
13    y = "Frecuencia"
14  ) +
15  theme_minimal()

```

En algunos problemas podría resultar útil estudiar una transformación como:

$$x' = \log(1 + x).$$

En R:

Transformar precipitación

```

1 datos_cluster_completos <- datos_cluster_completos %>%
2   mutate(
3     log_precipitacion =
4       log1p(
5         precipitacion
6       )
7   )

```

Buena práctica

Las transformaciones deben justificarse a partir de la distribución y del significado de la variable. No deben aplicarse automáticamente.

15.23. Nombrar los clusters

Después de caracterizar los grupos, podemos asignar nombres descriptivos.

Supongamos que el análisis muestra claramente tres perfiles.

Podríamos construir:

Asignar nombres interpretativos

```
1 resultado_cluster <- resultado_cluster %>%
2   mutate(
3     tipo_dia = case_when(
4       cluster == "1"
5         ~ "perfil A",
6
7       cluster == "2"
8         ~ "perfil B",
9
10      cluster == "3"
11        ~ "perfil C"
12    )
13  )
```

Después de analizar los centroides podríamos reemplazar esos nombres por etiquetas más informativas.

Error frecuente

Asignar nombres como “día cálido” o “día lluvioso” antes de revisar las características reales de los clusters.

Idea clave

Primero agrupamos. Después caracterizamos. Finalmente interpretamos y, si corresponde, asignamos nombres.

15.24. ¿Qué ocurre si incluimos varias estaciones?

Una extensión natural consiste en repetir el análisis utilizando varias estaciones.

Sin embargo, debemos preguntarnos:

- ¿todas tienen las mismas variables disponibles?;
- ¿los períodos observados son comparables?;
- ¿las diferencias entre estaciones dominarán los clusters?;
- ¿queremos agrupar días o queremos indirectamente agrupar estaciones?;

Después de construir los clusters podemos estudiar:

Clusters por estación

```
1 resultado_varias_estaciones %>%  
2   count(  
3     estacion,  
4     cluster  
5   ) %>%  
6  
7   group_by(  
8     estacion  
9   ) %>%  
10  
11  mutate(  
12    proporcion =  
13      n / sum(n)  
14  )
```

Idea clave

Si casi todas las observaciones de una estación caen en un único cluster, puede ser necesario investigar si el algoritmo está encontrando tipos de días o simplemente diferencias sistemáticas entre estaciones.

15.25. Regresión y clustering responden preguntas diferentes

En la sección anterior trabajamos con una estructura como:

Terminal

```
variables explicativas  
  |  
  v  
variable respuesta conocida  
  |  
  v  
regresion
```

En clustering trabajamos con:

Terminal

```
variables descriptivas  
  |  
  v
```

```

similitud entre observaciones
|
v
grupos no definidos previamente

```

Podemos resumir:

	Regresión	Clustering
Variable objetivo	Sí	No
Tipo	Supervisado	No supervisado
Pregunta típica	¿Qué valor esperamos?	¿Qué observaciones son similares?
Resultado	Predicción o relación	Asignación a grupos
Ejemplo	Predecir temperatura	Identificar tipos de días

15.26. Un flujo de clustering aplicado

Podemos resumir el procedimiento:

Terminal

```

formular una pregunta
|
v
seleccionar variables
|
v
revisar calidad y faltantes
|
v
estudiar distribuciones
|
v
transformar si corresponde
|
v
estandarizar
|
v
probar diferentes valores de k
|
v
ajustar k-means
|
v

```

```
caracterizar clusters
    |
    v
visualizar
    |
    v
relacionar con otras variables
    |
    v
interpretar
```

Idea clave

Ejecutar `kmeans()` es solamente una pequeña parte del análisis.

15.27. Actividad para probar

Para probar

Cada grupo deberá utilizar una base vinculada a su proyecto y formular una pregunta exploratoria que pueda abordarse mediante clustering.

El objetivo debe estar expresado en términos de similitud entre observaciones y no debe utilizar una variable objetivo conocida para definir los grupos.

Para probar

El trabajo deberá incluir:

1. definir qué representa una observación que será agrupada;
2. seleccionar entre tres y seis variables numéricas relevantes;
3. justificar por qué esas variables fueron elegidas;
4. revisar valores faltantes;
5. revisar las distribuciones de las variables;
6. identificar posibles valores extremos;
7. decidir si alguna variable requiere una transformación;
8. estandarizar las variables utilizadas;
9. aplicar **k-means**;
10. probar diferentes valores de k ;
11. construir el gráfico del método del codo;
12. utilizar al menos otra evidencia para discutir la elección de k , como silhouette o interpretación de los grupos;
13. agregar la asignación de cluster a la base original;
14. indicar cuántas observaciones pertenecen a cada cluster;
15. construir una tabla que caracterice los clusters mediante sus variables originales;
16. construir al menos dos visualizaciones de los grupos;

17. proponer una interpretación para cada cluster.

Para probar

Respondan además:

1. ¿qué significado práctico parece tener cada cluster?;
2. ¿algún cluster está asociado a un período, región, estación, categoría u otra característica que no fue utilizada directamente en el algoritmo?;
3. ¿los clusters son claramente diferentes o existen muchas observaciones próximas a las fronteras?;
4. ¿qué efecto creen que tendría no estandarizar las variables?;
5. ¿existen observaciones extremas que influyan fuertemente en los resultados?;
6. ¿cambiar el valor de k altera sustancialmente la interpretación?;
7. ¿los grupos encontrados resultan útiles para comprender el problema del proyecto?

Idea clave

Un clustering útil no es necesariamente aquel que produce grupos perfectamente separados. Debe producir una estructura que podamos describir, investigar y relacionar con la pregunta del problema.

15.28. Cierre de la sección

En esta sección introdujimos el clustering como herramienta de análisis exploratorio no supervisado.

Aprendimos que los métodos basados en distancias requieren especial atención a las escalas de las variables y utilizamos estandarización para construir una representación comparable.

Aplicamos **k-means**, estudiamos diferentes valores de k , utilizamos variabilidad interna y silhouette como herramientas de apoyo y caracterizamos los grupos obtenidos utilizando las variables originales.

También vimos que los clusters no contienen una interpretación automática: debemos volver a los datos y estudiar qué diferencia a cada grupo.

Con regresión y clustering incorporamos dos formas diferentes de análisis multivariable. En la próxima sección volveremos a la dimensión temporal de los datos para estudiar agregaciones, tendencias, cambios y comparaciones a lo largo del tiempo.