

## 14. Relaciones entre variables y regresión lineal aplicada

### 14.1. Objetivo de la sección

En las secciones anteriores construimos un flujo de trabajo que incluye lectura de datos, limpieza, transformación, visualización, almacenamiento en una base relacional y consultas mediante SQL.

A partir de esta sección comenzaremos a utilizar los datos preparados para responder preguntas de análisis.

Nos concentraremos primero en relaciones entre variables numéricas y en el ajuste de modelos de regresión lineal.

El objetivo no es desarrollar toda la teoría estadística de la regresión, sino aprender a:

- formular una pregunta sobre la relación entre variables;
- explorar esa relación gráficamente;
- calcular correlaciones;
- ajustar un modelo de regresión lineal simple;
- interpretar sus coeficientes;
- obtener valores predichos;
- estudiar residuos;
- calcular métricas básicas de error;
- construir modelos con más de una variable explicativa;
- separar datos para ajuste y evaluación;
- evitar interpretaciones que los datos no permiten sostener.

#### Idea clave

Un modelo no comienza con una función de R. Comienza con una pregunta que queremos responder utilizando los datos.

### 14.2. Formular una pregunta

Utilizaremos nuevamente la base meteorológica como ejemplo de referencia.

Podemos formular preguntas como:

- ¿Existe una relación entre temperatura media y humedad relativa?
- ¿La radiación solar está asociada con la temperatura media?

- ¿Podemos describir parte de la variación de la temperatura media utilizando otras variables meteorológicas?

Estas preguntas no son equivalentes a preguntar:

¿Una variable causa los cambios observados en otra?

#### Idea clave

Encontrar una asociación entre dos variables no demuestra una relación causal.

Un modelo puede ser útil para describir relaciones o generar predicciones, pero la interpretación causal requiere información y supuestos adicionales.

### 14.3. Preparar los datos

Comenzamos leyendo la base procesada.

#### Preparar datos para el análisis

```
1 library(tidyverse)
2 library(lubridate)
3
4 datos <- read_csv(
5   "data/processed/datos_meteorologicos_tidyverse.csv"
6 )
7
8 glimpse(datos)
```

Para los primeros ejemplos utilizaremos:

- temp\_media;
- hr\_media;
- rad\_solar;
- precipitacion.

Podemos construir una tabla específica para el análisis:

#### Seleccionar variables de análisis

```
1 analisis <- datos %>%
2   select(
3     Fecha,
4     estacion,
5     temp_media,
6     hr_media,
```

```

7       rad_solar,
8       precipitacion
9     )
10
11 glimpse(analisis)

```

### Buena práctica

Conviene construir una tabla de trabajo que contenga solamente las variables necesarias para el análisis actual. La base procesada completa debe conservarse.

## 14.4. Revisar valores faltantes antes de modelar

Antes de ajustar un modelo debemos revisar qué observaciones están disponibles.

### Revisar faltantes

```

1 analisis %>%
2   summarise(
3     across(
4       everything(),
5       ~ sum(is.na(.x))
6     )
7   )

```

Si queremos estudiar inicialmente la relación entre temperatura y humedad:

### Preparar observaciones completas

```

1 temp_humedad <- analisis %>%
2   drop_na(
3     temp_media,
4     hr_media
5   )
6
7 cat(
8   "Registros disponibles:",
9   nrow(temp_humedad),
10  "\n"
11 )

```

### Buena práctica

Antes de usar `drop_na`, conviene registrar cuántas observaciones se están eliminando y preguntarse si esas ausencias pueden introducir un sesgo.

## 14.5. Explorar la relación gráficamente

Antes de calcular un modelo podemos construir un gráfico de dispersión.

### Temperatura y humedad relativa

```
1 ggplot(  
2   temp_humedad,  
3   aes(  
4     x = hr_media,  
5     y = temp_media  
6   )  
7 ) +  
8   geom_point() +  
9   labs(  
10    title = "Temperatura media y humedad relativa",  
11    x = "Humedad relativa media",  
12    y = "Temperatura media"  
13  ) +  
14  theme_minimal()
```

Al observar el gráfico podemos preguntarnos:

- ¿parece existir alguna relación?;
- ¿la relación parece aproximadamente lineal?;
- ¿existen grupos diferentes?;
- ¿hay valores extremos?;
- ¿la dispersión parece cambiar a lo largo del eje horizontal?

### Idea clave

Antes de ajustar un modelo, conviene mirar los datos.

## 14.6. Correlación entre dos variables

Una medida frecuente para estudiar la asociación lineal entre dos variables numéricas es el coeficiente de correlación.

En R podemos calcularlo con:

### Correlación entre temperatura y humedad

```
1 cor(  
2   temp_humedad$temp_media,  
3   temp_humedad$hr_media  
4 )
```

El coeficiente de correlación toma valores entre  $-1$  y  $1$ .

De forma general:

- valores próximos a  $1$  indican una asociación lineal positiva fuerte;
- valores próximos a  $-1$  indican una asociación lineal negativa fuerte;
- valores próximos a  $0$  indican poca asociación lineal.

#### Error frecuente

Una correlación cercana a cero no significa necesariamente que no exista ninguna relación entre las variables. Puede existir una relación no lineal.

#### Error frecuente

Una correlación elevada tampoco demuestra causalidad.

## 14.7. Matriz de correlaciones

Cuando tenemos varias variables numéricas podemos construir una matriz de correlaciones.

### Seleccionar variables numéricas

```
1 variables_cor <- analisis %>%  
2   select(  
3     temp_media,  
4     hr_media,  
5     rad_solar,  
6     precipitacion  
7   )
```

Luego:

### Matriz de correlaciones

```
1 matriz_cor <- cor(  
2   variables_cor,  
3   use = "pairwise.complete.obs"
```

```
4 )  
5  
6 print(matriz_cor)
```

### Cómo leer este código

El argumento:

#### Terminal

```
use = "pairwise.complete.obs"
```

indica que cada correlación se calcula utilizando las observaciones disponibles para ese par de variables.

### Buena práctica

Cuando se utiliza una estrategia para trabajar con valores faltantes, esa decisión debe quedar explícita. Diferentes pares de variables pueden terminar utilizando cantidades distintas de observaciones.

## 14.8. Regresión lineal simple

Supongamos que queremos utilizar la humedad relativa media para describir parte de la variación de la temperatura media.

Un modelo lineal simple puede escribirse como:

$$y = \beta_0 + \beta_1 x + \varepsilon.$$

En nuestro ejemplo:

- $y$  corresponde a la temperatura media;
- $x$  corresponde a la humedad relativa media;
- $\beta_0$  es el intercepto;
- $\beta_1$  representa el cambio esperado en  $y$  asociado a una unidad de cambio en  $x$ ;
- $\varepsilon$  representa la parte no explicada por el modelo.

En R utilizamos `lm`:

### Ajustar una regresión lineal

```
1 modelo_simple <- lm(  
2   temp_media ~ hr_media,  
3   data = temp_humedad  
4 )  
5  
6 print(modelo_simple)
```

### Cómo leer este código

La fórmula:

#### Terminal

```
temp_media ~ hr_media
```

puede leerse como:

modelar `temp_media` en función de `hr_media`.

## 14.9. Consultar los coeficientes

Podemos consultar directamente los coeficientes:

### Coeficientes del modelo

```
1 coef(modelo_simple)
```

También podemos guardarlos:

### Guardar coeficientes

```
1 beta_0 <- coef(modelo_simple)[1]  
2 beta_1 <- coef(modelo_simple)[2]  
3  
4 print(beta_0)  
5 print(beta_1)
```

El modelo ajustado tiene entonces la forma:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

#### Idea clave

La pendiente debe interpretarse utilizando las unidades de las variables.

Por ejemplo, si `hr_media` está expresada en puntos porcentuales, la pendiente representa el cambio estimado en temperatura asociado a un aumento de un punto porcentual en humedad, manteniendo el contexto del modelo utilizado.

### 14.10. Obtener un resumen del modelo

La función `summary` muestra información más completa:

#### Resumen de la regresión

```
1 summary(modelo_simple)
```

Entre los elementos que aparecen podemos encontrar:

- estimaciones de los coeficientes;
- errores estándar;
- estadísticos asociados a los coeficientes;
- residuos;
- coeficiente de determinación  $R^2$ ;
- $R^2$  ajustado.

En esta unidad curricular nos concentraremos principalmente en la interpretación práctica del modelo, sus predicciones y sus errores.

#### Idea clave

Un modelo no debe evaluarse solamente por un único número obtenido de `summary`. También debemos revisar su comportamiento sobre los datos.

### 14.11. El coeficiente de determinación

El valor  $R^2$  indica qué proporción de la variación observada de la variable respuesta es explicada por el modelo, dentro del conjunto utilizado para ajustarlo.

Podemos obtenerlo mediante:

#### Obtener R cuadrado

```
1 resumen_modelo <- summary(modelo_simple)
2
```

```
3 r2 <- resumen_modelo$r.squared
4
5 print(r2)
```

### Error frecuente

Un  $R^2$  elevado no garantiza que un modelo sea adecuado para todas las finalidades, y un  $R^2$  bajo no implica automáticamente que el modelo carezca de utilidad.

## 14.12. Visualizar la recta ajustada

Podemos representar el modelo sobre los datos:

### Datos y regresión lineal

```
1 ggplot(
2   temp_humedad,
3   aes(
4     x = hr_media,
5     y = temp_media
6   )
7 ) +
8   geom_point() +
9   geom_smooth(
10    method = "lm",
11    se = FALSE
12  ) +
13  labs(
14    title = "Regresion lineal entre humedad y temperatura",
15    x = "Humedad relativa media",
16    y = "Temperatura media"
17  ) +
18  theme_minimal()
```

### Idea clave

La recta representa el comportamiento estimado por el modelo. Los puntos muestran la variabilidad real que permanece alrededor de esa estimación.

## 14.13. Obtener predicciones

Podemos agregar a nuestra tabla los valores estimados por el modelo.

### Agregar predicciones

```
1 temp_humedad <- temp_humedad %>%
2   mutate(
3     temp_predicha =
4       predict(
5         modelo_simple,
6         newdata = temp_humedad
7       )
8   )
9
10 temp_humedad %>%
11   select(
12     temp_media,
13     hr_media,
14     temp_predicha
15   ) %>%
16   head()
```

### Cómo leer este código

La función `predict` utiliza el modelo ajustado para calcular una predicción para cada observación.

#### 14.14. Calcular residuos

El residuo es la diferencia entre el valor observado y el valor predicho:

$$e_i = y_i - \hat{y}_i.$$

Podemos calcularlo:

### Calcular residuos

```
1 temp_humedad <- temp_humedad %>%
2   mutate(
3     residuo =
4       temp_media -
5       temp_predicha
6   )
7
8 temp_humedad %>%
9   select(
10    temp_media,
11    temp_predicha,
12    residuo
```

```
13     ) %>%  
14     head()
```

#### Idea clave

Los residuos contienen información sobre aquello que el modelo no consiguió representar.

### 14.15. Visualizar residuos

Una visualización simple consiste en representar residuos frente a valores predichos.

#### Residuos y valores predichos

```
1  ggplot(  
2    temp_humedad,  
3    aes(  
4      x = temp_predicha,  
5      y = residuo  
6    )  
7  ) +  
8    geom_point() +  
9    geom_hline(  
10     yintercept = 0  
11   ) +  
12   labs(  
13     title = "Residuos del modelo",  
14     x = "Temperatura predicha",  
15     y = "Residuo"  
16   ) +  
17   theme_minimal()
```

Podemos observar:

- si los residuos aparecen aproximadamente distribuidos alrededor de cero;
- si existe algún patrón sistemático;
- si aparecen observaciones con errores especialmente grandes;
- si la dispersión cambia según el valor predicho.

#### Buena práctica

Si los residuos muestran una estructura clara, puede ser una señal de que el modelo lineal no está representando adecuadamente alguna característica de los datos.

## 14.16. Métricas básicas de error

Podemos resumir el tamaño de los errores mediante diferentes métricas.

Una de ellas es el error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

En R:

### Calcular MAE

```
1 mae <- temp_humedad %>%
2   summarise(
3     MAE =
4       mean(
5         abs(residuo)
6       )
7   )
8
9 print(mae)
```

Otra posibilidad es la raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

### Calcular RMSE

```
1 rmse <- temp_humedad %>%
2   summarise(
3     RMSE =
4       sqrt(
5         mean(
6           residuo^2
7         )
8       )
9   )
10
11 print(rmse)
```

### Cómo leer este código

El MAE expresa el tamaño medio del error utilizando valores absolutos.  
El RMSE penaliza con mayor intensidad los errores grandes debido al uso del cuadrado.

### Idea clave

Una métrica solamente tiene sentido cuando sabemos sobre qué datos fue calculada.

## 14.17. Evaluar con datos diferentes a los utilizados para ajustar

Hasta ahora ajustamos el modelo y calculamos sus errores sobre las mismas observaciones.

Esto puede dar una visión demasiado optimista de su capacidad predictiva.

Una estrategia sencilla consiste en separar los datos en:

- conjunto de entrenamiento;
- conjunto de evaluación.

Como estamos trabajando con datos temporales, podemos realizar una separación cronológica.

### Ordenar los datos temporalmente

```
1 modelo_datos <- temp_humedad %>%  
2   arrange(Fecha)
```

Podemos utilizar, por ejemplo, aproximadamente el 80 % inicial para entrenamiento.

### Definir punto de separación

```
1 n <- nrow(modelo_datos)  
2  
3 corte <- floor(  
4   0.8 * n  
5 )
```

Luego:

### Separar entrenamiento y evaluación

```
1 entrenamiento <- modelo_datos %>%  
2   slice(  
3     1:corte
```

```

4     )
5
6     evaluacion <- modelo_datos %>%
7       slice(
8         (corte + 1):n
9       )
10
11     cat(
12       "Entrenamiento:",
13       nrow(entrenamiento),
14       "\n"
15     )
16
17     cat(
18       "Evaluacion:",
19       nrow(evaluacion),
20       "\n"
21     )

```

#### Idea clave

Cuando existe un orden temporal y el objetivo futuro es realizar predicciones hacia adelante, una separación cronológica suele ser más apropiada que mezclar aleatoriamente observaciones pasadas y futuras.

### 14.18. Ajustar solamente con entrenamiento

Ahora ajustamos el modelo:

#### Modelo sobre entrenamiento

```

1 modelo_train <- lm(
2   temp_media ~ hr_media,
3   data = entrenamiento
4 )

```

Y predecimos sobre el conjunto de evaluación:

#### Predecir datos de evaluación

```

1 evaluacion <- evaluacion %>%
2   mutate(
3     temp_predicha =
4       predict(
5         modelo_train,

```

```

6         newdata = evaluacion
7     ),
8
9     residuo =
10         temp_media -
11         temp_predicha
12 )

```

Calculamos métricas:

### Evaluar el modelo

```

1  metricas <- evaluacion %>%
2      summarise(
3          MAE =
4              mean(
5                  abs(residuo)
6              ),
7
8          RMSE =
9              sqrt(
10                 mean(
11                     residuo^2
12                 )
13            )
14      )
15
16  print(metricas)

```

### Buena práctica

Las métricas de evaluación deben calcularse, siempre que sea posible, sobre observaciones que no fueron utilizadas para ajustar el modelo.

## 14.19. Comparar observado y predicho

Podemos visualizar ambas series:

### Preparar observado y predicho

```

1  comparacion <- evaluacion %>%
2      select(
3          Fecha,
4          temp_media,
5          temp_predicha

```

```

6      ) %>%
7
8      pivot_longer(
9        cols = c(
10         temp_media,
11         temp_predicha
12       ),
13
14       names_to =
15         "serie",
16
17       values_to =
18         "temperatura"
19     )

```

Luego:

#### Valores observados y predichos

```

1  ggplot(
2    comparacion,
3    aes(
4      x = Fecha,
5      y = temperatura,
6      color = serie
7    )
8  ) +
9    geom_line() +
10   labs(
11     title = "Temperatura observada y predicha",
12     x = "Fecha",
13     y = "Temperatura",
14     color = "Serie"
15   ) +
16   theme_minimal()

```

#### Idea clave

Visualizar observado y predicho permite detectar comportamientos que una única métrica puede ocultar.

### 14.20. Regresión lineal múltiple

La temperatura puede estar relacionada con más de una variable.

Podemos construir un modelo con varios predictores.

Primero preparamos observaciones completas:

#### Preparar varias variables

```
1 datos_multiple <- analisis %>%
2   drop_na(
3     temp_media,
4     hr_media,
5     rad_solar,
6     precipitacion
7   )
```

Luego ajustamos:

#### Regresión lineal múltiple

```
1 modelo_multiple <- lm(
2   temp_media
3   ~ hr_media
4   + rad_solar
5   + precipitacion,
6
7   data =
8     datos_multiple
9 )
10
11 summary(modelo_multiple)
```

El modelo tiene ahora una estructura general:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3.$$

#### Cómo leer este código

Cada coeficiente representa la asociación estimada de una variable con la respuesta considerando simultáneamente las demás variables incluidas en el modelo.

#### Error frecuente

Interpretar cada coeficiente de una regresión múltiple como si hubiera sido calculado de forma aislada.

### 14.21. Relaciones entre variables explicativas

Antes de agregar muchas variables a un modelo también conviene observar cómo se relacionan entre ellas.

### Correlaciones entre predictores

```
1 datos_multiple %>%  
2   select(  
3     hr_media,  
4     rad_solar,  
5     precipitacion  
6   ) %>%  
7  
8   cor(  
9     use =  
10      "pairwise.complete.obs"  
11   )
```

Si dos variables contienen información muy similar, la interpretación de sus coeficientes puede volverse más difícil.

#### Idea clave

Agregar más variables no garantiza automáticamente un mejor modelo.

### 14.22. Comparar modelos

Podemos construir más de un modelo y comparar su desempeño sobre un conjunto de evaluación.

Por ejemplo:

#### Dos modelos candidatos

```
1 modelo_1 <- lm(  
2   temp_media ~ hr_media,  
3   data = entrenamiento  
4 )  
5  
6 modelo_2 <- lm(  
7   temp_media  
8   ~ hr_media  
9   + rad_solar,  
10  data = entrenamiento  
11 )
```

Para cada modelo podemos calcular predicciones sobre el mismo conjunto de evaluación y comparar métricas.

### Buena práctica

Cuando comparamos modelos, debemos evaluarlos sobre el mismo conjunto de datos y utilizando las mismas métricas.

## 14.23. ¿Debemos mezclar todas las estaciones?

Una pregunta importante en nuestra base es si tiene sentido ajustar un único modelo utilizando todas las estaciones conjuntamente.

Las estaciones pueden presentar:

- condiciones ambientales diferentes;
- períodos diferentes de observación;
- disponibilidad diferente de sensores;
- patrones distintos de valores faltantes.

Podemos visualizar la relación por estación:

### Relación por estación

```
1 ggplot(  
2   temp_humedad,  
3   aes(  
4     x = hr_media,  
5     y = temp_media  
6   )  
7 ) +  
8   geom_point() +  
9   geom_smooth(  
10     method = "lm",  
11     se = FALSE  
12   ) +  
13   facet_wrap(  
14     ~ estacion  
15   ) +  
16   theme_minimal()
```

### Idea clave

Antes de combinar grupos diferentes dentro de un único modelo, conviene verificar si las relaciones observadas son razonablemente comparables.

## 14.24. Un flujo de regresión aplicada

Podemos resumir el procedimiento como:

## Terminal

```
formular una pregunta
|
v
seleccionar variables
|
v
revisar calidad y faltantes
|
v
visualizar relaciones
|
v
calcular asociaciones
|
v
separar entrenamiento/evaluacion
|
v
ajustar modelo
|
v
predecir
|
v
calcular residuos y metricas
|
v
visualizar resultados
|
v
interpretar con cautela
```

### Idea clave

El comando `lm` ocupa solamente una pequeña parte del flujo completo.

## 14.25. Actividad para probar

### Para probar

Cada grupo deberá utilizar una base vinculada a su proyecto de aprendizaje automático y seleccionar una pregunta que pueda explorarse mediante regresión lineal.

La pregunta debe identificar:

- una variable respuesta numérica;
- al menos una posible variable explicativa numérica.

### Para probar

El trabajo deberá incluir:

1. justificar las variables seleccionadas;
2. revisar valores faltantes;
3. indicar cuántas observaciones quedan disponibles para el análisis;
4. construir un gráfico de dispersión;
5. calcular la correlación entre las variables principales;
6. ajustar una regresión lineal simple;
7. interpretar el intercepto y la pendiente dentro del contexto del problema;
8. obtener valores predichos;
9. calcular residuos;
10. construir un gráfico de residuos;
11. calcular MAE y RMSE;
12. separar un conjunto de entrenamiento y otro de evaluación;
13. volver a ajustar el modelo utilizando solamente el conjunto de entrenamiento;
14. calcular las métricas sobre el conjunto de evaluación;
15. construir un gráfico que compare valores observados y predichos.

### Para probar

Luego, construyan un segundo modelo incorporando al menos una variable explicativa adicional.

Comparen los dos modelos utilizando el mismo conjunto de evaluación.

Respondan:

1. ¿qué modelo obtuvo menor MAE?;
2. ¿qué modelo obtuvo menor RMSE?;
3. ¿agregar otra variable produjo una mejora relevante?;
4. ¿aparecen patrones en los residuos?;
5. ¿hay diferencias importantes entre grupos, estaciones, regiones o períodos?;
6. ¿qué limitaciones tendría este modelo si fuera utilizado para realizar predicciones reales?

### Idea clave

El objetivo no es encontrar el modelo con más variables ni obtener una métrica perfecta. El objetivo es construir, evaluar e interpretar un procedimiento de análisis reproducible.

## 14.26. Cierre de la sección

En esta sección pasamos de la exploración visual de relaciones a la construcción de modelos de regresión lineal.

Utilizamos correlaciones y gráficos de dispersión para explorar asociaciones, ajustamos modelos simples y múltiples, generamos predicciones, estudiamos residuos y calculamos

métricas de error.

También introducimos una idea fundamental: un modelo debe evaluarse sobre datos distintos de aquellos utilizados para ajustarlo.

La regresión trabaja a partir de una variable respuesta conocida que queremos describir o predecir.

En la próxima sección abordaremos una situación diferente: buscar estructuras dentro de los datos sin definir previamente una variable objetivo. Para ello introduciremos métodos de clustering, comenzando por el algoritmo **k-means**.